

Laporan Analisis Segmentasi Pelanggan dengan K-Means Clustering

1. Ringkasan Eksekutif

Laporan ini menyajikan hasil analisis segmentasi pelanggan menggunakan metode **K-Means Clustering** berdasarkan tiga variabel utama: usia, pendapatan tahunan, dan skor pengeluaran. Dari 235 baris data mentah, setelah proses pembersihan diperoleh **220 pelanggan bersih** yang berhasil dikelompokkan ke dalam **4 segmen (cluster)** dengan karakteristik yang berbeda-beda. Hasil segmentasi ini dapat digunakan sebagai dasar strategi pemasaran yang lebih tepat sasaran untuk setiap kelompok pelanggan.

2. Sumber Data

File	Deskripsi	Dimensi
dataset_pelanggan_mentah.csv	Data pelanggan sebelum diproses (raw)	235 baris x 5 kolom
proyek_akhir_clustering.ipynb	Notebook Python berisi seluruh proses analisis	8 sel kode
dataset_pelanggan_terkluster.csv	Data hasil akhir setelah clustering	220 baris x 7 kolom

Kolom pada data mentah: `CustomerID`, `Usia`, `Pendapatan_Tahunan_juta`, `Skor_Pengeluaran_1_100`, `Kategori_Member` (Regular/Premium).

3. Metodologi

Proses analisis pada notebook mengikuti enam tahap berikut:

Langkah 1 — Memuat Dataset

Dataset mentah dimuat dengan dimensi awal **235 baris x 5 kolom**.

Langkah 2 — Cleaning Data & Preprocessing

- Duplikasi:** ditemukan dan dihapus **15 baris data duplikat**.
- Penanganan outlier/nilai tidak valid:** nilai dianggap tidak wajar diubah menjadi `NaN` dengan aturan:
 - `Usia > 90` → dianggap tidak valid
 - `Skor_Pengeluaran_1_100 < 1` → dianggap tidak valid
 - `Pendapatan_Tahunan_juta > 200` → dianggap tidak valid

- **Imputasi nilai kosong:** seluruh nilai `NaN` diisi menggunakan **nilai median** dari masing-masing kolom.
- **Encoding kategorikal:** `Kategori_Member` diubah menjadi numerik (`Regular = 0`, `Premium = 1`).
- Hasil akhir setelah pembersihan: **220 baris data bersih**.

Langkah 3 — Feature Scaling

Tiga fitur numerik (`Usia`, `Pendapatan_Tahunan_juta`, `Skor_Pengeluaran_1_100`) distandarisasi menggunakan `StandardScaler` agar memiliki skala yang setara sebelum proses clustering.

Langkah 4 — Penentuan Jumlah Cluster (Metode Elbow)

Algoritma K-Means dijalankan untuk $k = 1$ sampai 10, dan nilai WCSS (Within-Cluster Sum of Squares) diplot untuk menentukan titik "siku" (elbow). Berdasarkan grafik ini, jumlah cluster optimal yang dipilih adalah $k = 4$.

Langkah 5 — Pelatihan Model K-Means Final

Model K-Means dilatih dengan `k=4`, menghasilkan:

- **Silhouette Score = 0.2301**

Skor ini berada pada kategori sedang-lemah, menandakan pemisahan antar cluster cukup terlihat namun ada sejumlah overlap antar segmen — hal yang wajar untuk data perilaku pelanggan yang bersifat kontinu.

Langkah 6 — Profiling Cluster

Setiap pelanggan diberi label cluster (0-3), lalu dianalisis rata-rata karakteristiknya dan disimpan ke `dataset_pelanggan_terkluster.csv`.

4. Hasil Segmentasi

4.1 Ukuran dan Profil Rata-Rata Tiap Cluster

Cluster	Jumlah Pelanggan	Rata-rata Usia	Rata-rata Pendapatan (juta)	Rata-rata Skor Pengeluaran
0	56	43.9	83.5	34.0
1	56	44.1	59.2	67.0
2	57	37.0	48.6	33.5
3	51	24.7	70.4	59.5

4.2 Komposisi Kategori Member per Cluster

Cluster	Premium	Regular	% Premium
0	24	32	42.9%
1	27	29	48.2%
2	27	30	47.4%
3	17	34	33.3%

4.3 Interpretasi Segmen

Cluster 0 — "Berpendapatan Tinggi, Hemat" (56 pelanggan) Usia paruh baya (~44 tahun) dengan pendapatan tertinggi di antara semua cluster (~83 juta), namun skor pengeluaran rendah (~34). Kelompok ini kemungkinan adalah pelanggan yang mampu secara finansial tetapi selektif atau jarang berbelanja — berpotensi menjadi target kampanye yang menonjolkan nilai/eksklusivitas produk.

Cluster 1 — "Pengeluaran Tinggi, Loyal" (56 pelanggan) Usia paruh baya (~44 tahun) dengan pendapatan menengah (~59 juta) tetapi skor pengeluaran tertinggi (~67). Ini adalah segmen paling bernilai dari sisi perilaku belanja — kandidat utama untuk program loyalitas dan penawaran retensi.

Cluster 2 — "Pendapatan Rendah, Hemat" (57 pelanggan) Usia relatif muda (~37 tahun), pendapatan terendah (~49 juta), dan skor pengeluaran rendah (~33). Segmen ini paling sensitif terhadap harga; cocok ditargetkan dengan promo, diskon, atau paket hemat.

Cluster 3 — "Muda, Pengeluaran Tinggi" (51 pelanggan) Kelompok termuda (~25 tahun) dengan pendapatan menengah-tinggi (~70 juta) dan skor pengeluaran cukup tinggi (~59). Proporsi Premium terendah (33.3%), mengindikasikan potensi besar untuk dikonversi dari Regular menjadi Premium melalui penawaran yang relevan dengan gaya hidup muda.

5. Visualisasi

Notebook menghasilkan dua visualisasi utama:

1. **Grafik Metode Elbow** — menunjukkan penurunan WCSS terhadap jumlah cluster ($k=1$ s.d. 10), digunakan untuk menentukan k optimal = 4.
2. **Scatter Plot Hasil Cluster** — memplot `Pendapatan_Tahunan_juta` vs `Skor_Pengeluaran_1_100`, dengan setiap cluster diberi warna berbeda, memperlihatkan pemisahan visual antar segmen pelanggan.

(Catatan: kedua grafik dihasilkan langsung di dalam notebook melalui `plt.show()` dan tidak disimpan sebagai file gambar terpisah, sehingga tidak disertakan sebagai gambar statis dalam laporan ini.)

6. Kesimpulan dan Rekomendasi

1. **Kualitas data:** Proses cleaning berhasil menangani duplikasi dan nilai tidak wajar (usia > 90, pendapatan > 200 juta, skor pengeluaran < 1) dengan imputasi median, menghasilkan dataset yang cukup bersih (220 dari 235 baris awal, atau ~93.6% data terpakai).
2. **Kualitas cluster:** Silhouette Score 0.2301 menunjukkan pengelompokan yang moderat — cukup baik untuk insight bisnis awal, namun dapat ditingkatkan lebih lanjut (lihat rekomendasi di bawah).
3. **Segmen paling bernilai:** Cluster 1 (pengeluaran tinggi, loyal) adalah target retensi utama, sementara Cluster 3 (muda, berpotensi tinggi) adalah target akuisisi/konversi Premium.
4. **Segmen sensitif harga:** Cluster 0 dan Cluster 2 memiliki skor pengeluaran rendah meski profil pendapatan berbeda — strategi pendekatan untuk keduanya perlu dibedakan (Cluster 0 lebih ke arah nilai/eksklusivitas, Cluster 2 lebih ke arah harga/promo).

Saran pengembangan lanjutan:

- Menguji algoritma clustering lain (misalnya DBSCAN atau Gaussian Mixture Model) untuk membandingkan kualitas segmentasi.
- Menambahkan fitur perilaku tambahan (frekuensi transaksi, riwayat kategori produk, dsb.) jika tersedia, untuk memperkaya profil setiap segmen.
- Melakukan validasi bisnis terhadap masing-masing segmen bersama tim pemasaran sebelum eksekusi kampanye.

Laporan ini disusun berdasarkan proses analisis pada `proyek_akhir_clustering.ipynb`, menggunakan `dataset_pelanggan_mentah.csv` sebagai input dan `dataset_pelanggan_terkluster.csv` sebagai output akhir.